

LUCRARE DE LICENȚĂ

Cererea și oferta de gaze naturale în context spațio-temporal.

Analize și predicții utilizând rețele neuronale convoluționale.

Conducător științific:
Prof. Univ. Dr. Stelian STANCU

Absolvent:
Alexandra-Elena DRĂGHICESCU

CUPRINS

- 01** INTRODUCERE
- 02** STADIUL CUNOAȘTERII
- 03** TEHNICI ȘI METODE DE CALCUL
- 04** METODOLOGIA CERCETĂRII
- 05** REZULTATE EMPIRICE
- 06** CONCLUZII
- 07** BIBLIOGRAFIE

INTRODUCERE

Acest studiu de caz are ca scop evidențierea utilității tehnicielor de calcul specifice domeniului de Inteligență Artificială și Machine Learning în procesele de analiză și predicție pentru piața de gaze naturale în contextul spațio-temporal actual.

Pentru predicția componentelor de cerere și ofertă de gaze naturale de la nivelul României am considerat utilă comparația rezultatelor obținute în urma a trei tehnici de calcul reprezentative:

- Modele Statistice Autoregresive de Medie Mobilă(ARIMA și SARIMA);
- Rețea neuronală recurrentă de tip Long Short-Term Memory(LSTM);
- Rețea neuronală convoluțională(CNN);



STADIUL CUNOAȘTERII

Informații despre diferitele concepe care stau la baza studiului de caz,
culese din literatura de specialitate;



**Piața de gaze naturale,
în general**

Factori de influență

Ipoteze de estimare

TEHNICI ȘI METODE DE CALCUL

1

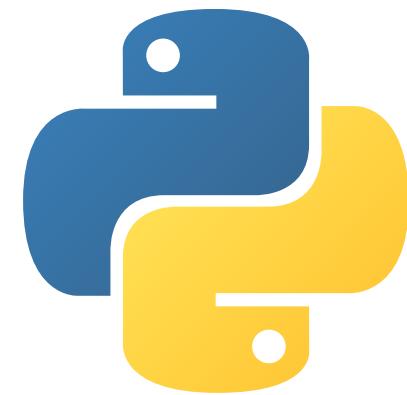
Rețelele Neuronale Convoluționale
CNN

2

Rețele Neuronale Recurrente
(tip Long Short-Term Memory)
LSTM

3

Modele Autoregresive
de Medie Mobilă
ARIMA/SARIMA



METODOLOGIE

- computarea soluției în limbajul de programare Python ;

**Descrierea
Datelor**

**Compunerea
Modelului
de Analiză**

**Alegerea
Modelului
Optim**

REZULTATE EMPIRICE

- rezultate numerice în urma rulării celor trei tehnici de calcul în Python ;
- etape următoare secvențial pentru a lua decizii ;

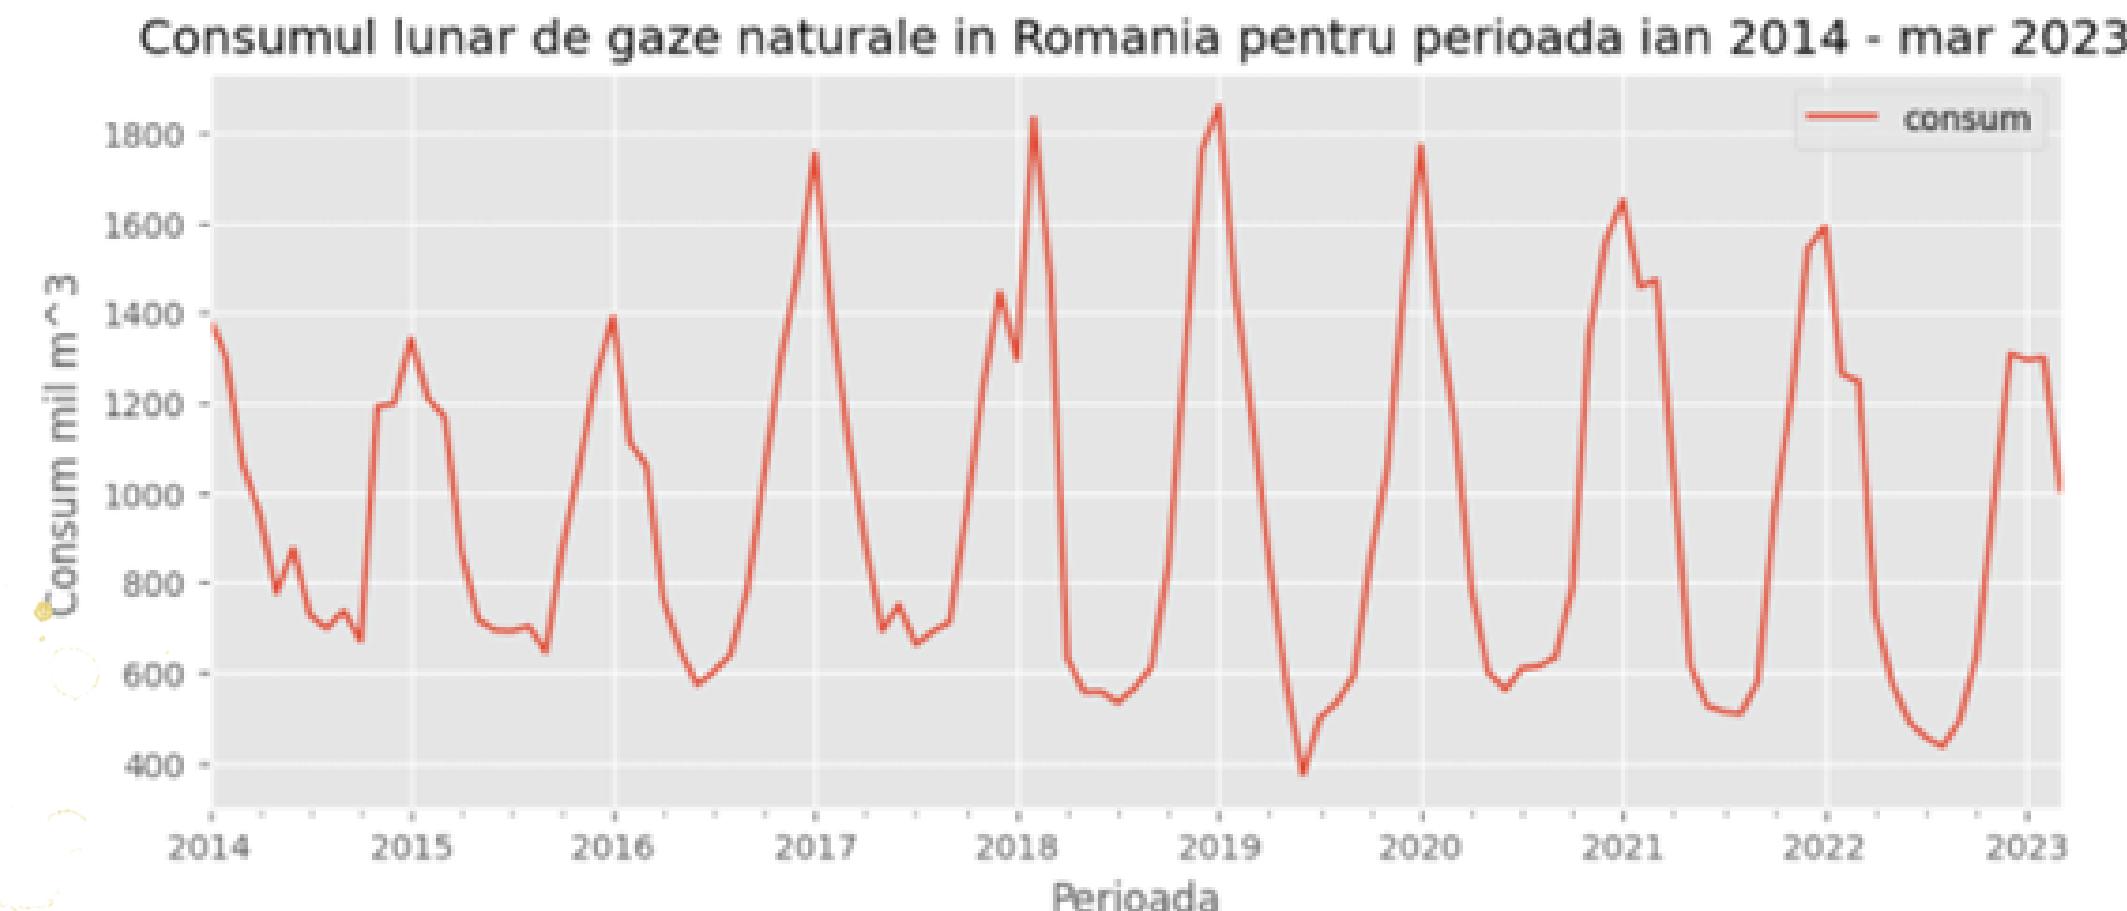
**Comparație
între valorile
reale și cele
previzionate**

**Comparație
între erorile de
previzionare
obținute**

**Graficul
evoluției
valorilor
previzionate**

Evoluția cererii de gaze naturale

- serie de timp cu componentă puternică de sezonialitate ;
- previziune bună printr-un model SARIMA(2, 1, 0)x(2, 1, 0, 12) ;



Grafic al seriei de consum înregistrat între ianuarie 2014 și martie 2023

	Test Set	SARIMA DIF	Bidirectional LSTM	CNN
2022-01-01	1591	1790.010277	1751.288733	1882.588623
2022-02-01	1263	1443.339967	1610.722466	1789.056274
2022-03-01	1247	1241.799860	1258.039004	1339.164917
2022-04-01	729	881.494829	915.747037	736.478760
2022-05-01	576	606.556299	665.005057	570.641663
2022-06-01	490	494.757107	522.244702	525.782776
2022-07-01	455	550.609003	468.772176	521.068909
2022-08-01	435	564.009903	504.903055	560.472290
2022-09-01	493	609.809662	623.453550	639.890015
2022-10-01	637	860.150203	832.814950	926.047119
2022-11-01	965	1221.171246	1156.465901	1299.844971
2022-12-01	1309	1526.660599	1540.602504	1505.904907
2023-01-01	1295	1732.728446	1738.852939	1691.733643
2023-02-01	1300	1439.207167	1595.415701	1377.489868
2023-03-01	1004	1312.313308	1266.091231	1257.972778

Valori previzionate pentru cererea de gaze

- rezultate valide pentru toate metodele ;
- SARIMA - 03/22 ;
- LSTM - 07/22 ;
- CNN - 02/23 ;

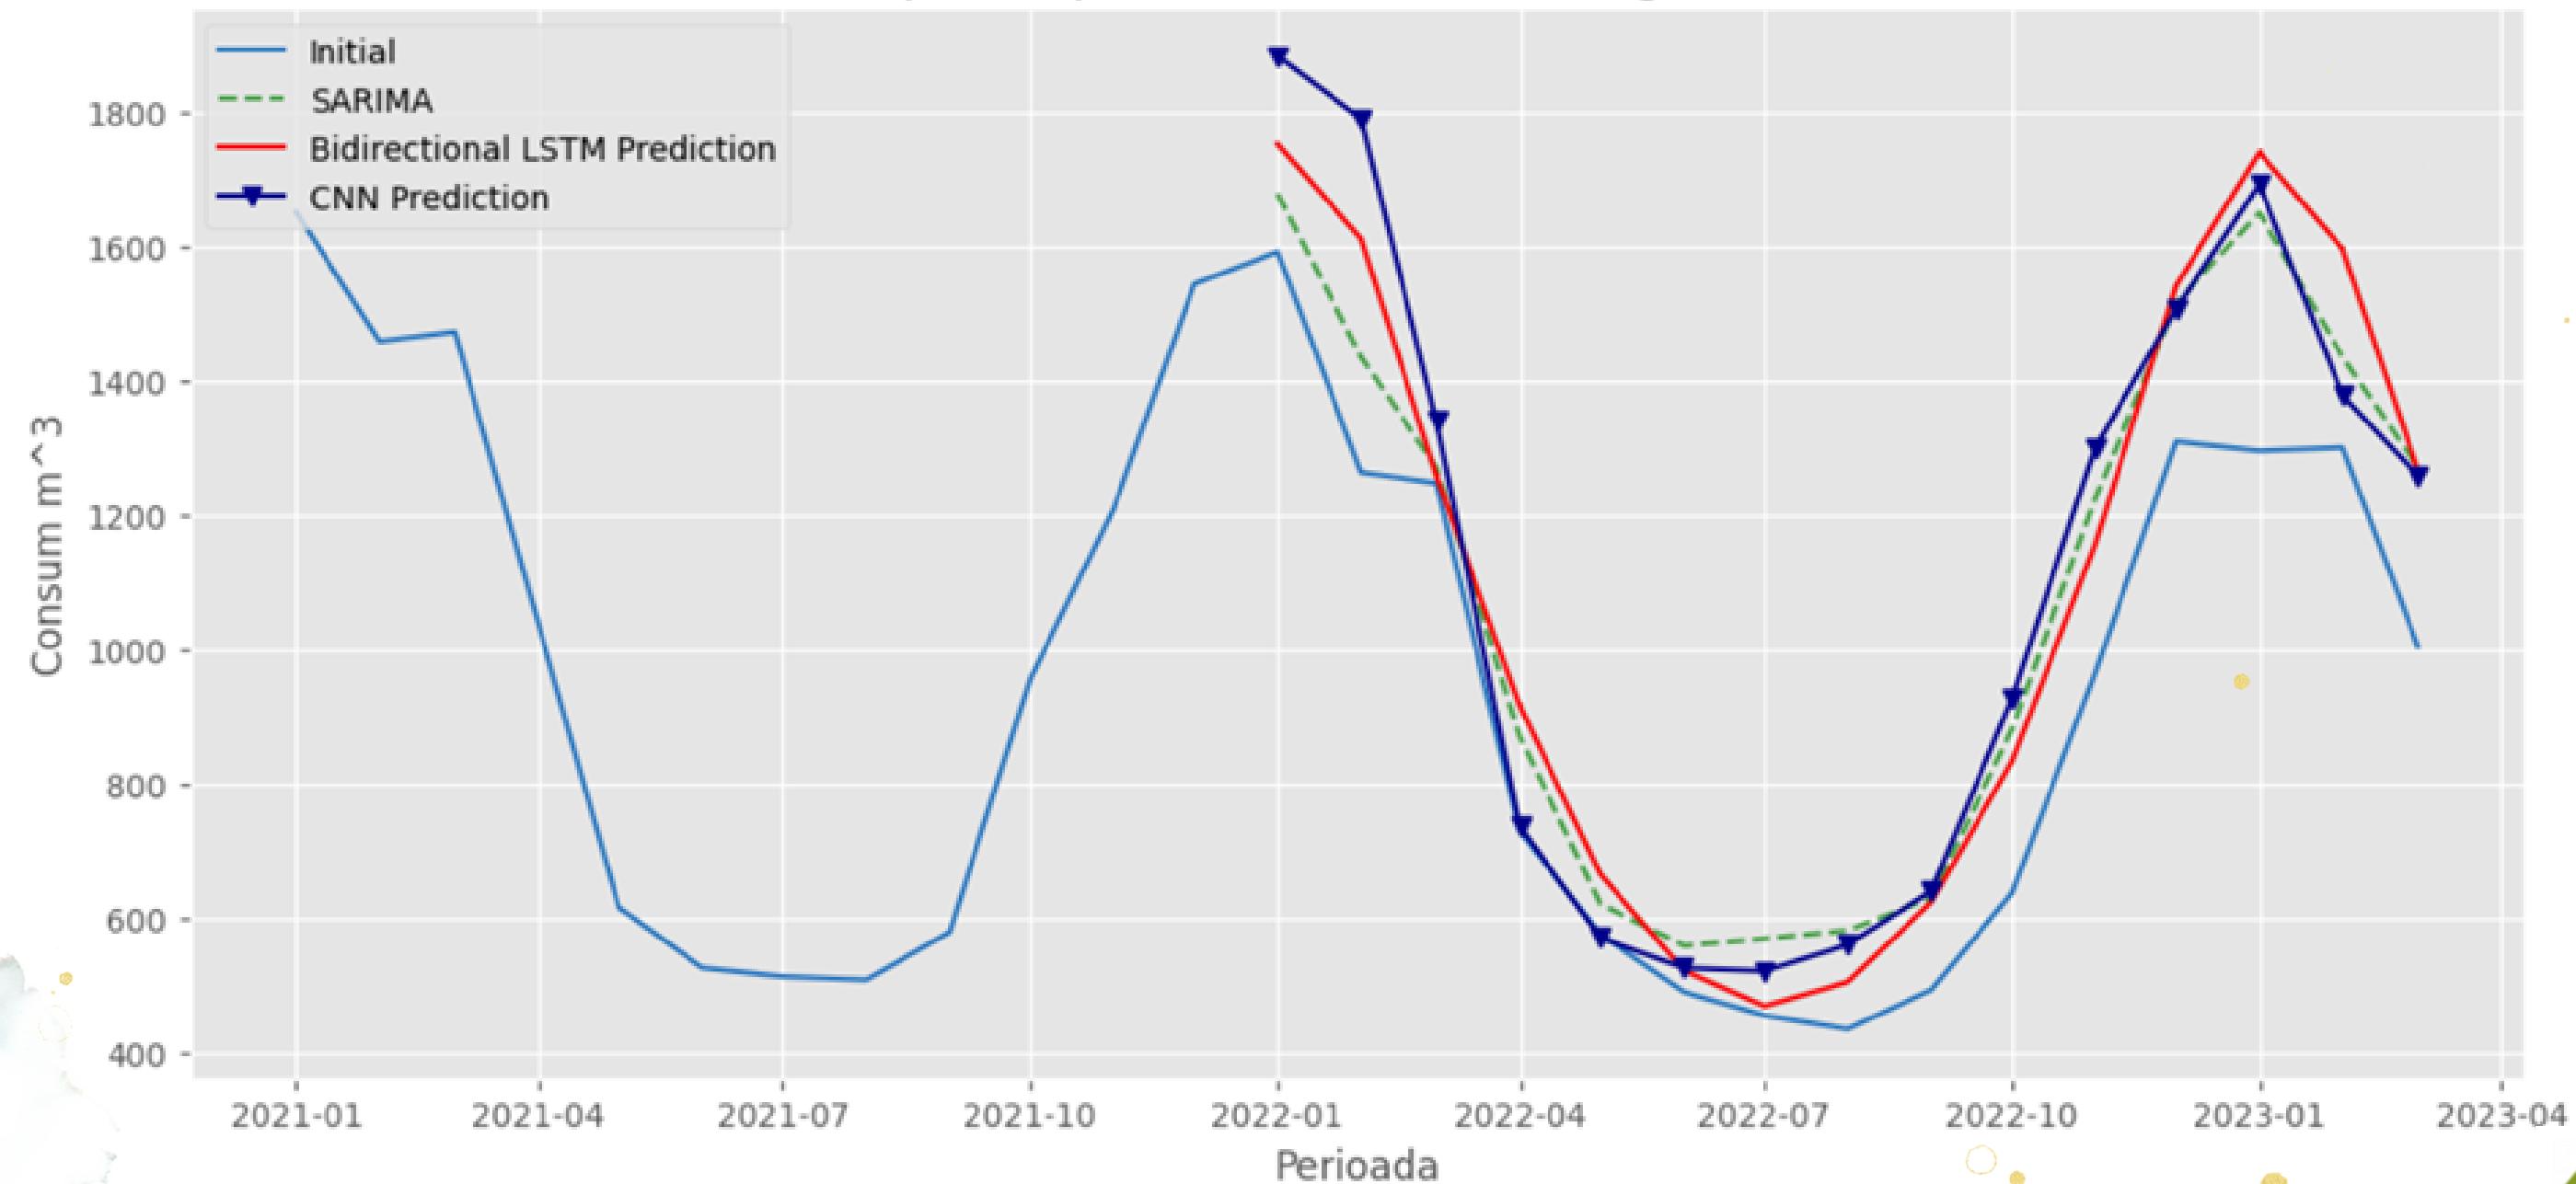
Erori de previzionare pentru cererea de gaze

- valori valide pentru toate metodele ;
- valori minime pentru metoda autoregresivă ;
- LSTM rezultate apropiate de SARIMA ;
- CNN metoda în ultima instanță ;

	Model	MSE	RMSE	MAPE
0	SARIMA DIF	40308.84	200.77	18.81
1	Bidirectional LSTM	46284.38	215.14	18.87
2	CNN	58376.60	241.61	20.45

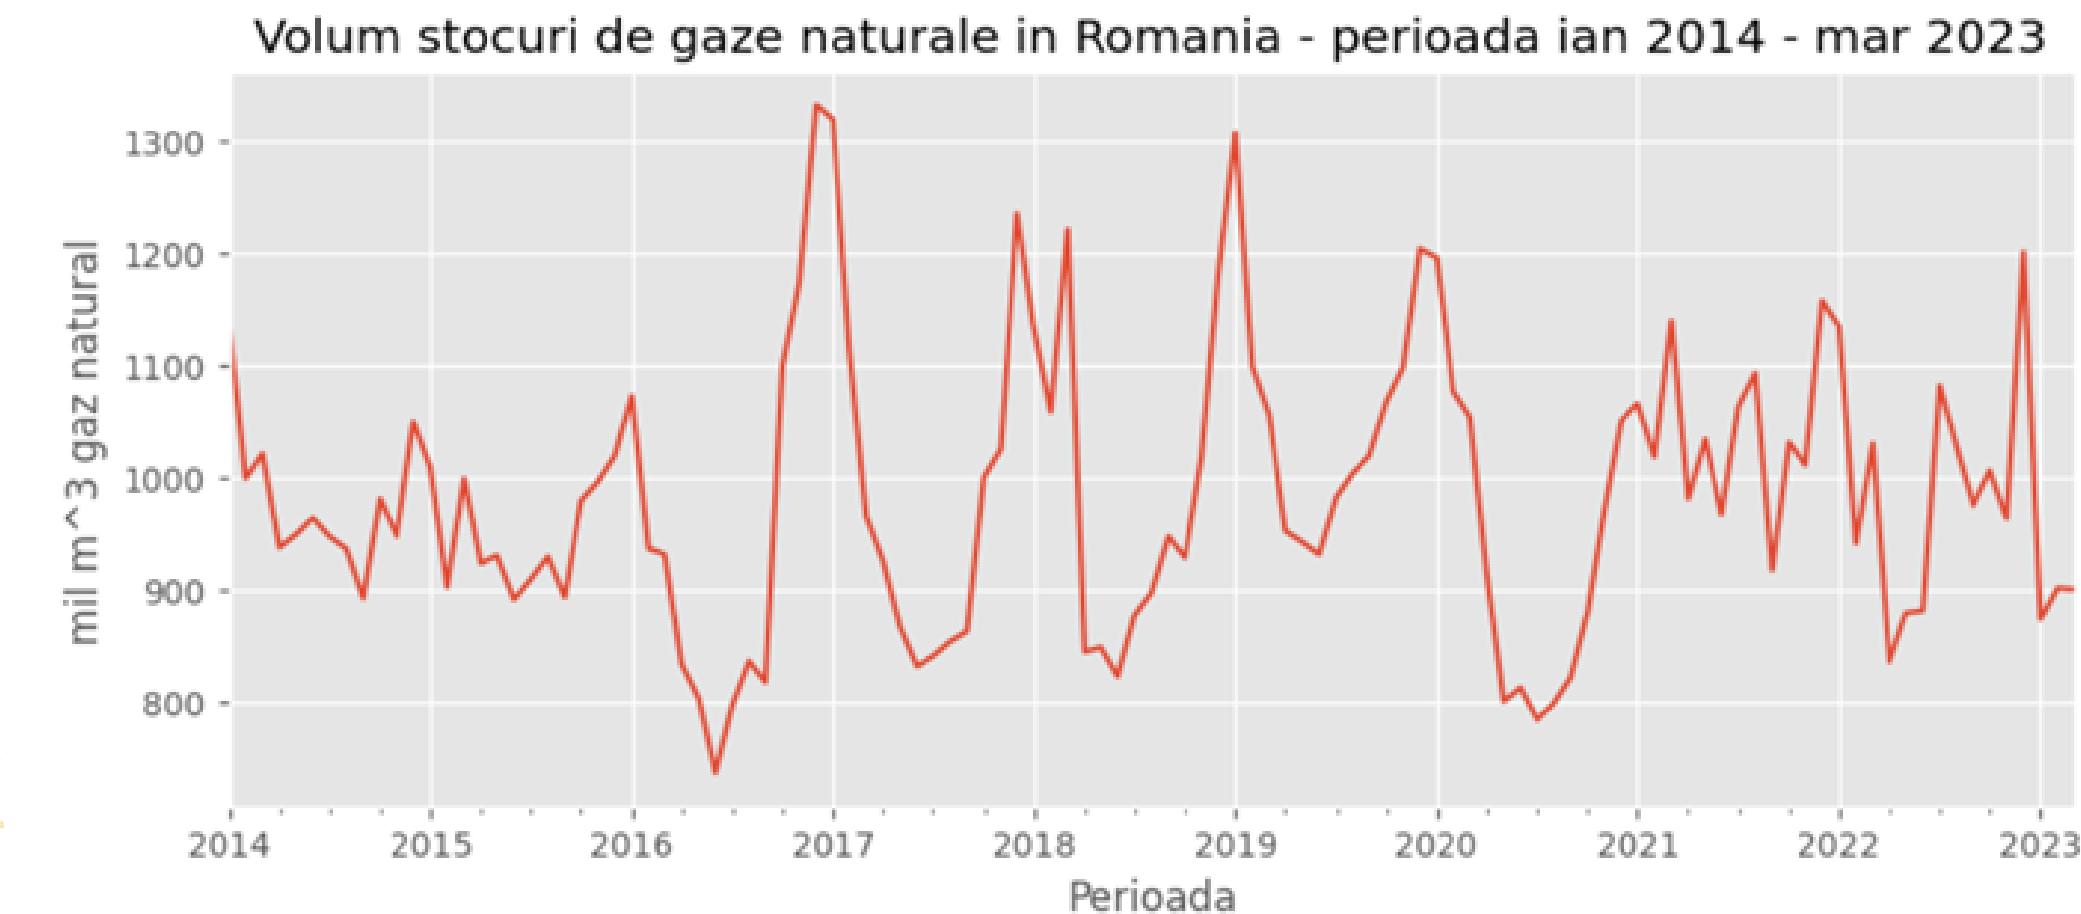
Evoluția valorilor previzionate pentru cererea de gaze

Diferite modele pentru predictia de consum de gaze naturale - zoom-in



Evoluția ofertei de gaze naturale

- serie de timp compusă din valoarea producției interne plus cea a importurilor;
- previziune bună printr-un model 1D CNN;
- serie cu volatilitate ridicată datorată factorilor externi de influență ;



Grafic al seriei de resursă înregistrat între ianuarie 2014 și martie 2023

	Test Set	SARIMA	Bidirectional LSTM	CNN
2022-01-01	1135	1217.063985	1136.649701	1157.845459
2022-02-01	941	1072.996302	1136.816839	1028.619873
2022-03-01	1030	1071.001088	1109.694948	1092.817627
2022-04-01	835	943.610443	1070.686979	927.757202
2022-05-01	879	911.003116	1033.013106	998.011719
2022-06-01	881	896.841990	981.519663	905.231384
2022-07-01	1082	929.367398	976.840033	893.101868
2022-08-01	1027	950.626532	964.791691	966.176331
2022-09-01	975	929.914147	980.594569	1033.775269
2022-10-01	1006	994.705505	994.603125	1157.474609
2022-11-01	963	1036.524807	1034.206343	1062.344971
2022-12-01	1201	1141.812874	1105.108815	1063.346313
2023-01-01	873	1155.294540	1139.549795	991.410950
2023-02-01	901	1055.789461	1158.339698	945.659241
2023-03-01	900	1087.158517	1115.197547	962.931274

Valori previzionate pentru oferta de gaze

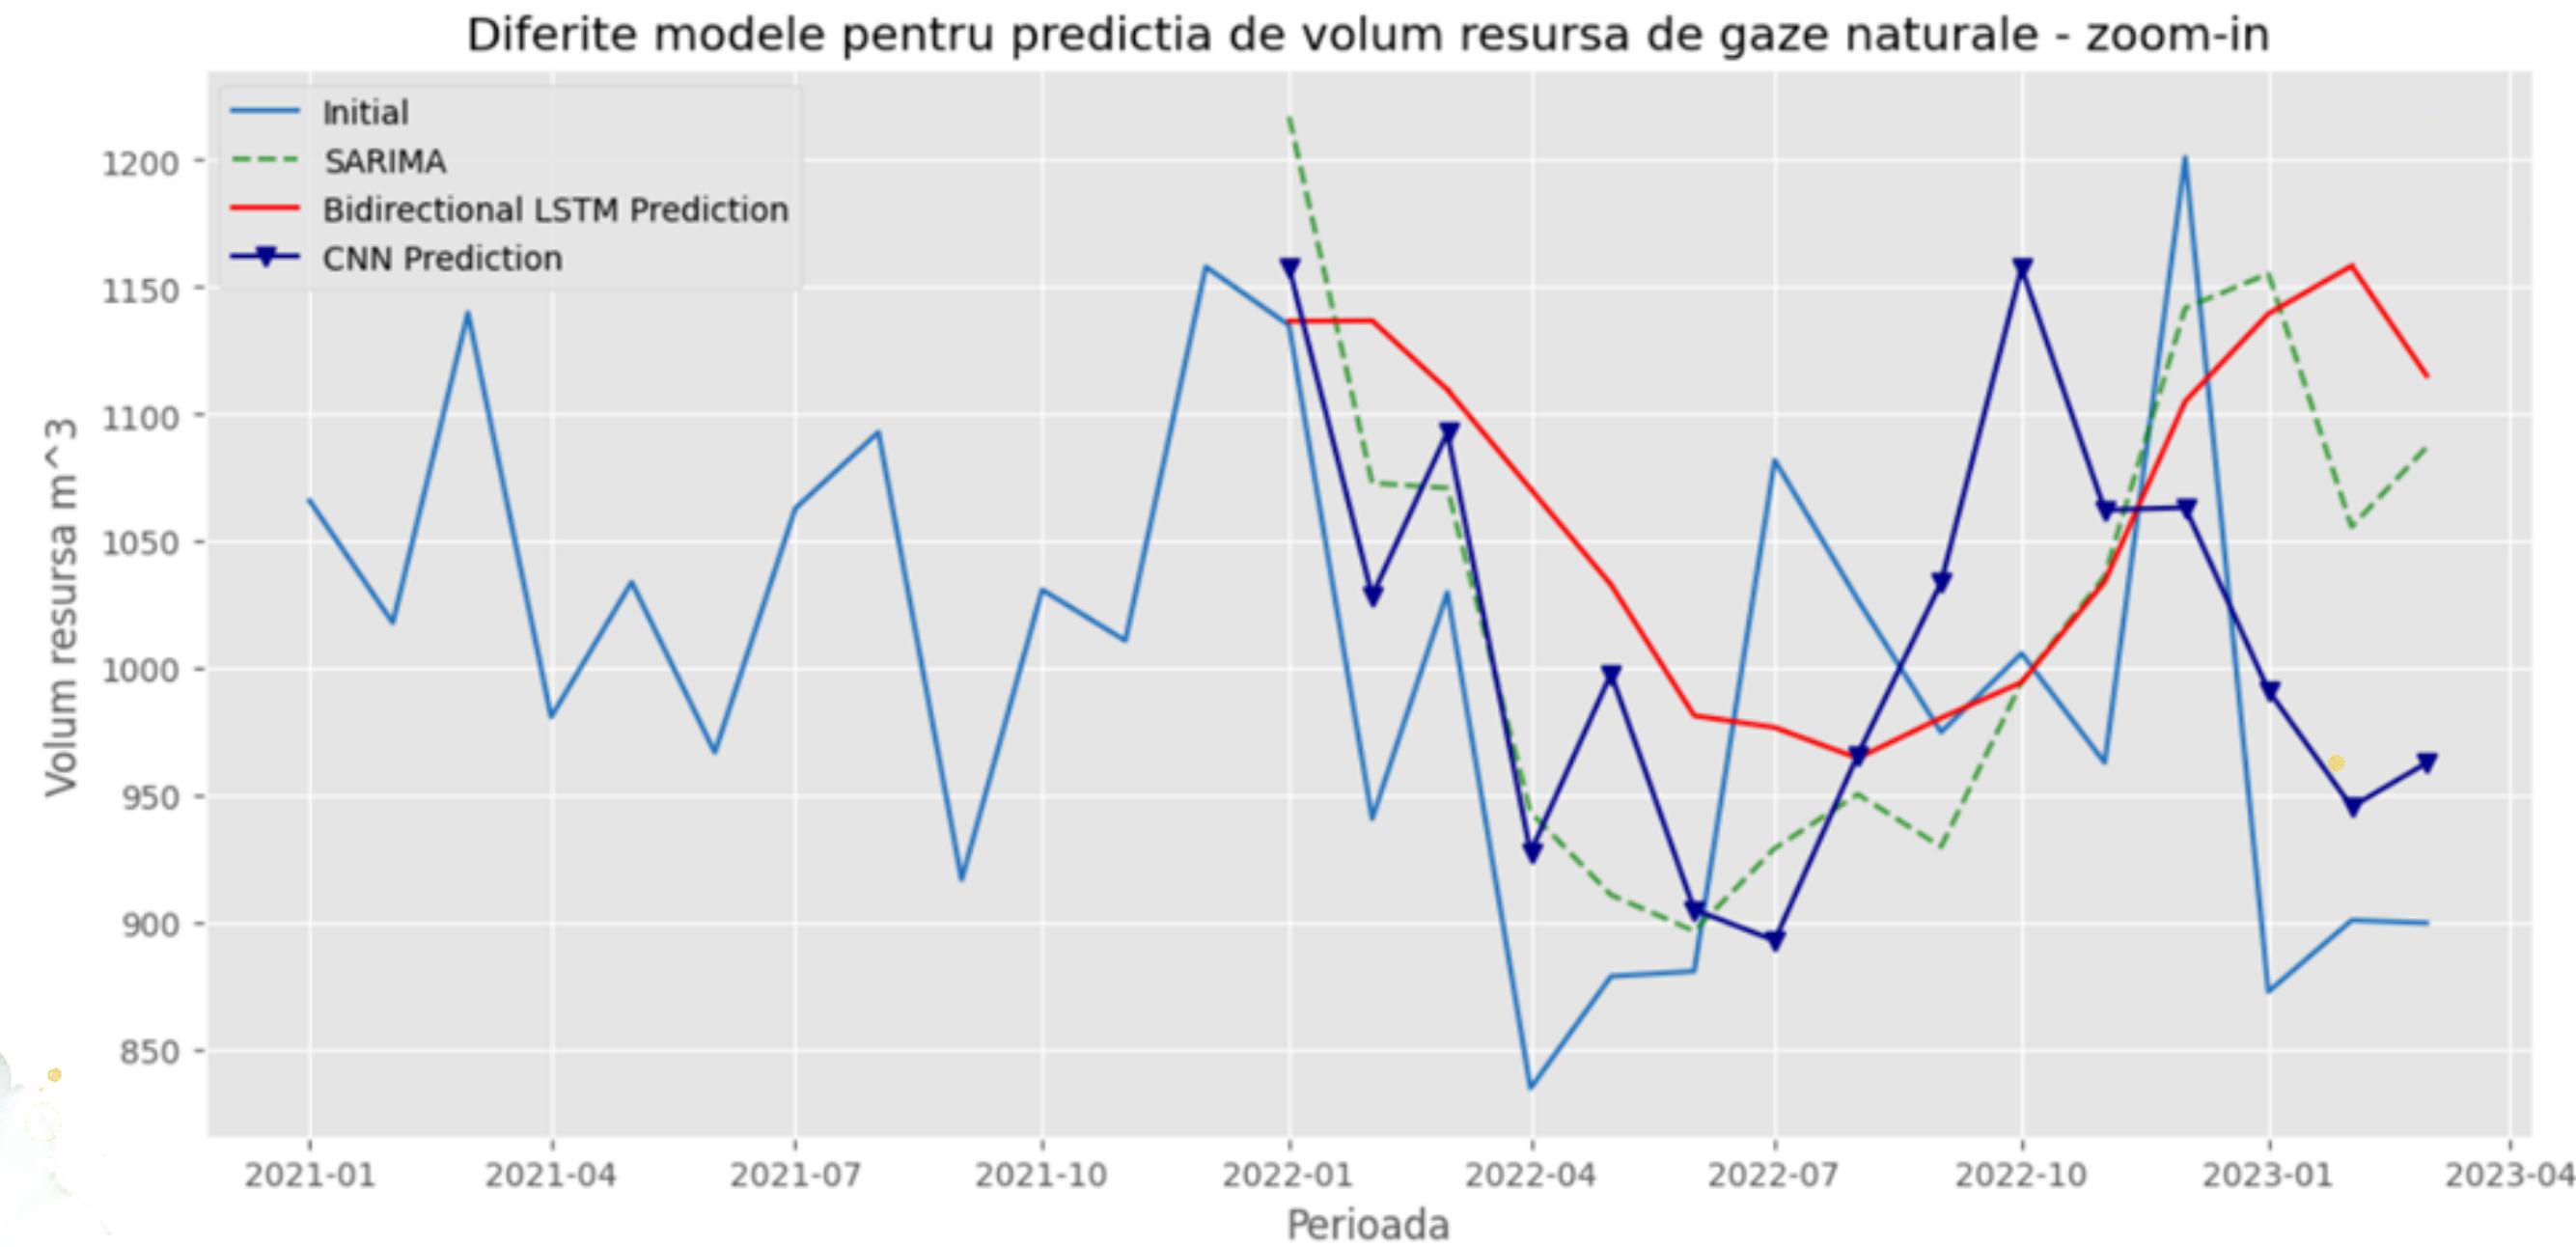
- rezultate valide pentru toate metodele ;
- SARIMA - 03/22 ;
- LSTM - 01/22 ;
- CNN - 03/23 ;

Erori de previzionare pentru oferta de gaze

- valori valide pentru toate metodele ;
- valori minime pentru metoda de rețea neuronală convolutională;
- SARIMA rezultate apropiate de CNN ;
- LSTM Bidirectional metoda în ultima instanță ;

	Model	MSE	RMSE	MAPE
0	SARIMA	14519.15	120.50	10.26
1	Bidirectional LSTM	23133.90	152.10	13.45
2	CNN	10005.01	100.03	9.11

Evoluția valorilor previzionate pentru oferta de gaze



CONCLUZII

- cererea de gaze este reprezentată prin variabila de consum ;
- oferta de gaze este reprezentată de suma producției interne și a importurilor ;
- cererea urmează un oarecare trend constant,dat de sezonialitate ;
- oferta prezintă volatilitate ridicată ;
- influență directă din cauza contextului spațio-temporal ;
- punct de plecare pentru decizii pe termen lung ;

**Previziune
cerere :**

- 500 m^3
- 1300 m^3

**Previziune
ofertă :**

- 900 m^3
- 1100 m^3

BIBLIOGRAFIE

- [1] **ANRE**. (2022) Rapoarte Lunare de Monitorizare Pentru Piața Internă de Gaze Naturale 2022 . ANRE. Available at: <https://arhiva.anre.ro/ro/gaze-naturale/rapoarte/rapoarte-piata-gaze-naturale/rapoarte-lunare-de-monitorizare-pentru-piata-interna-de-gaze-naturale-2022>
- [2] **EUROSTAT**. (2023d) Supply, Transformation and Consumption of Gas. Available at: https://ec.europa.eu/eurostat/web/products-datasets/-/nrg_cb_gas
- [3] **Petkovic, M., Koch, T. and Zittel, J.** (2022) 'Deep Learning for Spatio-Temporal Supply and Demand Forecasting in Natural Gas Transmission Networks'. Energy Science and Engineering, 10(6). DOI: 10.1002/ese3.932.
- [4] **Rick, R. and Berton, L.** (2022) 'Energy Forecasting Model Based on CNN-LSTM-AE for Many Time Series with Unequal Lengths'. Engineering Applications of Artificial Intelligence, 113. DOI: 10.1016/j.engappai.2022.104998.
- [5] **Stelian Stancu**. (2020) Machine Learning, Deep Learning, Deep Neural Network in Mediul R. Teorie Si Aplicatii. colecția cibernetică. București: Editura ASE .
- [6] **Wang, J. and Li, N.** (2020) 'Influencing Factors and Future Trends of Natural Gas Demand in the Eastern, Central and Western Areas of China Based on the Grey Model'. Natural Gas Industry B, 7(5). DOI: 10.1016/j.ngib.2020.09.005.

**VĂ MULTUMIMESCU
PENTRU ATENȚIE!**

Absolvent:

Alexandra-Elena DRĂGHICESCU

București | 2023

